

Apéndice D: Manual Técnico

Práctica: Implementación del algoritmo ID3 en RapidMiner

1. Descripción general del sistema

El sistema implementado corresponde a la ejecución del algoritmo de clasificación **ID3 (Iterative Dichotomiser 3)** mediante la herramienta de minería de datos **RapidMiner**, aplicado al conjunto de datos *Tic-Tac-Toe Endgame*. El objetivo principal es generar un modelo de árbol de decisión capaz de clasificar automáticamente las posiciones finales del juego, así como evaluar su desempeño mediante métricas estadísticas.

El sistema permite:

- Cargar el conjunto de datos desde archivos compatibles.
- Construir un árbol de decisión utilizando el criterio de ganancia de información.
- Evaluar el modelo mediante un conjunto de prueba.
- Obtener métricas de desempeño como exactitud, precisión, sensibilidad y tasa de error.
- Visualizar la estructura del árbol generado y rastrear trayectorias de clasificación.

2. Implementación en RapidMiner

2.1. Requerimientos de software

Para la ejecución del sistema se requiere:

- **RapidMiner Studio**.
- Sistema operativo Windows, Linux o macOS.
- Java Runtime Environment (JRE) instalado.

2.2. Operadores utilizados

La implementación del algoritmo ID3 se realizó mediante los siguientes operadores de RapidMiner:

- **Read CSV / Retrieve**: carga del conjunto de datos.
- **Split Data**: división del conjunto en entrenamiento y prueba.
- **Decision Tree**: generación del árbol de decisión mediante ganancia de información.
- **Apply Model**: aplicación del modelo al conjunto de prueba.
- **Performance (Classification)**: cálculo de métricas de desempeño.

2.3. Estructura de los datos de entrada

El conjunto de datos *Tic-Tac-Toe Endgame* contiene registros correspondientes a configuraciones finales del tablero. Cada objeto está descrito por nueve atributos categóricos que representan las posiciones del tablero y una variable de clase.

2.3.1. Atributos

Cada registro contiene los siguientes atributos:

- top-left-square
- top-middle-square
- top-right-square
- middle-left-square
- middle-middle-square
- middle-right-square
- bottom-left-square
- bottom-middle-square
- bottom-right-square

Cada atributo puede tomar los valores:

$$\{x, o, b\}$$

donde x y o representan las fichas de los jugadores y b una casilla vacía.

2.3.2. Variable de clase

La variable objetivo corresponde al resultado final del juego, con dos posibles valores:

$$\{positive, negative\}$$

donde **positive** indica una posición ganadora y **negative** una no ganadora.

2.4. Flujo funcional del sistema

El funcionamiento técnico del sistema se organiza en las siguientes etapas:

2.4.1. Carga de datos

Los datos se importan en RapidMiner mediante los operadores de lectura. Se verifica que todos los atributos categóricos y la clase estén correctamente identificados.

2.4.2. División de datos

Se utiliza el operador **Split Data** para separar el conjunto en datos de entrenamiento y prueba, permitiendo evaluar el modelo de forma objetiva.

2.4.3. Construcción del árbol

El operador **Decision Tree** genera el árbol de decisión aplicando el criterio de ganancia de información, seleccionando en cada nodo el atributo que maximiza la reducción de la entropía.

2.4.4. Clasificación

El modelo obtenido se aplica sobre el conjunto de prueba mediante el operador **Apply Model**, generando las predicciones de clase correspondientes.

2.4.5. Evaluación del modelo

Se emplea el operador **Performance (Classification)** para obtener métricas de desempeño, tales como exactitud, precisión, sensibilidad y tasa de error, así como la matriz de confusión.

2.5. Métricas generadas

RapidMiner calcula automáticamente las siguientes métricas:

- **Exactitud (Accuracy):** proporción de clasificaciones correctas.
- **Precisión (Precision):** proporción de verdaderos positivos respecto a las predicciones positivas.
- **Sensibilidad (Recall):** proporción de verdaderos positivos respecto al total real de positivos.
- **Tasa de error (Classification Error):** proporción de clasificaciones incorrectas.
- **Matriz de confusión:** tabla que resume los aciertos y errores de clasificación.

2.6. Visualización del árbol de decisión

RapidMiner permite observar gráficamente la estructura del árbol generado, mostrando:

- Nodos internos correspondientes a los atributos.
- Ramas que representan los valores posibles.
- Hojas finales con la clase asignada.

Esto facilita la interpretación del proceso de decisión y el rastreo de trayectorias seguidas por cada objeto clasificado.

2.7. Archivos de salida

El sistema genera como salida:

- Reporte de métricas de desempeño.
- Matriz de confusión.
- Visualización gráfica del árbol de decisión.
- Registro de trayectorias para nuevos datos.

Estos resultados pueden exportarse en formato `.txt` o `.csv` para su análisis y documentación.

2.8. Consideraciones técnicas

- El conjunto de datos debe estar correctamente formateado y sin valores faltantes.
- Los atributos deben ser categóricos para una correcta aplicación del algoritmo ID3.
- La correcta separación entre entrenamiento y prueba es fundamental para evitar sobreajuste.