

Apéndice B: Marco Teórico

Práctica 2: Implementación del algoritmo de clasificación ID3

1. Minería de datos y clasificación

La minería de datos es una disciplina que tiene como objetivo principal la extracción de conocimiento útil a partir de grandes volúmenes de información. Mediante el uso de técnicas estadísticas, matemáticas y de aprendizaje automático, se busca identificar patrones, relaciones y tendencias que permitan apoyar la toma de decisiones.

Dentro de este campo, la **clasificación** es una tarea de aprendizaje supervisado que consiste en asignar una etiqueta o clase a un objeto, basándose en un conjunto de datos previamente etiquetado. El objetivo es construir un modelo capaz de predecir correctamente la clase de nuevos datos a partir de la información aprendida.

2. Aprendizaje supervisado

El aprendizaje supervisado es un enfoque en el que el modelo se entrena utilizando ejemplos compuestos por atributos de entrada y su correspondiente clase. A partir de estos ejemplos, el sistema aprende la relación existente entre las características y la etiqueta, para posteriormente poder clasificar datos desconocidos.

En esta práctica, las clases corresponden a los resultados finales del juego del gato (*tic-tac-toe*), representados como *positive* y *negative*, de acuerdo con la configuración del tablero.

3. Árboles de decisión

Los **árboles de decisión** son modelos de clasificación que representan el proceso de toma de decisiones mediante una estructura jerárquica. Están compuestos por nodos internos que representan atributos, ramas que indican valores posibles y hojas que contienen la clase final.

Estos modelos permiten dividir progresivamente el conjunto de datos en subconjuntos más homogéneos, facilitando la interpretación de las reglas que conducen a una determinada clasificación. Una de sus principales ventajas es su alta interpretabilidad, ya que el proceso de decisión puede representarse gráficamente.

4. Algoritmo ID3

El algoritmo **ID3 (Iterative Dichotomiser 3)** es un método utilizado para construir árboles de decisión a partir de datos categóricos. Su principio fundamental es la selección del atributo que maximiza la **ganancia de información**, con el objetivo de reducir la incertidumbre en cada partición del conjunto de datos.

El proceso general del algoritmo ID3 es:

1. Calcular la entropía del conjunto total.

2. Calcular la ganancia de información de cada atributo.
3. Seleccionar el atributo con mayor ganancia como nodo del árbol.
4. Dividir el conjunto de datos según los valores del atributo seleccionado.
5. Repetir el proceso de forma recursiva hasta alcanzar un criterio de parada.

5. Entropía

La **entropía** es una medida que cuantifica el grado de incertidumbre o desorden presente en un conjunto de datos. Se utiliza para evaluar qué tan homogéneo es un conjunto respecto a sus clases. Matemáticamente, se define como:

$$H(S) = - \sum_{i=1}^n p_i \log_2(p_i) \quad (1)$$

donde:

- S representa el conjunto de datos.
- p_i es la proporción de ejemplos pertenecientes a la clase i .
- n es el número total de clases.

Un valor bajo de entropía indica que el conjunto es más homogéneo, mientras que un valor alto indica mayor desorden.

6. Ganancia de información

La **ganancia de información** mide la reducción de entropía obtenida al dividir un conjunto de datos según un atributo específico. Permite seleccionar el atributo que genera la mejor separación entre clases. Se define como:

$$GI(S, A) = H(S) - \sum_{v \in \text{Valores}(A)} \frac{|S_v|}{|S|} \cdot H(S_v) \quad (2)$$

donde:

- A es el atributo evaluado.
- S_v es el subconjunto de datos donde el atributo A toma el valor v .
- $|S|$ es el número total de instancias.

7. Matriz de confusión

La **matriz de confusión** es una herramienta utilizada para evaluar el desempeño de un modelo de clasificación. Permite visualizar el número de aciertos y errores cometidos por el clasificador, comparando las clases reales con las clases predichas.

Real / Predicho	Positive	Negative
Positive	TP	FN
Negative	FP	TN

(3)

donde:

- TP = Verdaderos Positivos.
- TN = Verdaderos Negativos.
- FP = Falsos Positivos.
- FN = Falsos Negativos.

8. Métricas de evaluación

A partir de la matriz de confusión, se pueden calcular diversas métricas que permiten evaluar el desempeño del clasificador:

8.1. Exactitud (Accuracy)

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (4)$$

8.2. Precisión (Precision)

$$Precision = \frac{TP}{TP + FP} \quad (5)$$

8.3. Sensibilidad (Recall)

$$Recall = \frac{TP}{TP + FN} \quad (6)$$

8.4. Tasa de error

$$Error = \frac{FP + FN}{TP + TN + FP + FN} \quad (7)$$

Estas métricas permiten analizar la calidad del modelo, identificando su capacidad para clasificar correctamente los datos.