



Bénemerita Universidad Autónoma de Puebla

FACULTAD DE CIENCIAS DE LA COMPUTACIÓN

INGENIERIA EN TECNOLOGÍAS DE LA INFORMACIÓN

Materia

Minería de Datos

Reporte

Práctica Árboles de decisión

Profesor:

Pedro T. Vera

Integrantes:

Blanca Flor Visca Cocotzin
Christopher Aguilar Mendez
Angel Fernando Ruiz Vasquez

16 de febrero del 2026

Índice

1. Introducción	3
2. Descripción del algoritmo ID3	3
2.1. Fórmulas utilizadas por RapidMiner	4
3. Procedimiento del algoritmo ID3	6
4. Metodología	7
5. Pruebas y Resultados Obtenidos en RapidMiner	7
5.1. Matriz de Confusión	7
5.2. Rastreo de trayectorias (New Data)	8
5.3. Árbol de decisión obtenido	10
6. Pruebas y Resultados Obtenidos Manualmente	10
6.1. Matriz de Confusión	10
6.2. Árbol de decisión obtenido manualmente	10
7. Comparación de Resultados Obtenidos	11
7.1. Comparación de matrices de confusión	11
7.2. Comparación de métricas de desempeño	12
8. Aplicación del Software Seleccionado	12
9. Conclusiones	13
10. Apéndices	14

Minería de Datos

Práctica Árboles de decisión

Blanca Flor Visca Cocotzin, Christopher Aguilar Mendez, Angel Fernando Ruiz Vasquez

16 de febrero del 2026

Resumen

En esta práctica se aplicó el algoritmo ID3 para la construcción de un árbol de decisión, utilizando la base de datos Tic-Tac-Toe Endgame. Se realizó el análisis de los atributos mediante el cálculo de la entropía y la ganancia de información para seleccionar las variables más relevantes y generar el modelo de clasificación. Posteriormente, se evaluó el desempeño del árbol mediante una matriz de confusión, obteniendo métricas como exactitud, precisión, sensibilidad y tasa de error. Finalmente, se empleó RapidMiner para comparar los resultados y analizar la clasificación de nuevos datos, comprobando la efectividad del algoritmo en la resolución del problema planteado.

1. Introducción

Los árboles de decisión son una técnica fundamental dentro de la minería de datos y el aprendizaje automático, debido a su capacidad para representar procesos de clasificación de forma clara y estructurada. Su principal ventaja es la facilidad de interpretación, ya que permiten visualizar las reglas que conducen a una determinada decisión.

En esta práctica se aborda el problema de clasificación utilizando la base de datos Tic-Tac-Toe Endgame, la cual describe diferentes configuraciones finales del juego del gato. Mediante la aplicación del algoritmo ID3, se busca construir un modelo capaz de identificar patrones relevantes en los datos y generar reglas de decisión precisas.

2. Descripción del algoritmo ID3

El algoritmo *Iterative Dichotomiser 3* (ID3) es un método de clasificación supervisada que construye un **árbol de decisión** a partir de un conjunto de datos etiquetados. En cada iteración, el algoritmo selecciona el atributo que maximiza la **ganancia de información**, con el objetivo de

reducir la incertidumbre en la clasificación. El proceso se repite de manera recursiva hasta que los datos quedan correctamente clasificados o no existen más atributos disponibles.

El árbol resultante permite representar las reglas de decisión de forma jerárquica, donde cada nodo interno corresponde a un atributo, cada rama representa un valor posible y cada hoja indica la clase final asignada.

2.1. Fórmulas utilizadas por RapidMiner

Sea la matriz de confusión:

Real / Predicho	Positive	Negative
Positive	TP	FN
Negative	FP	TN

(1)

donde:

- TP = Verdaderos Positivos.
- TN = Verdaderos Negativos.
- FP = Falsos Positivos.
- FN = Falsos Negativos.

1) **Entropía:** mide el grado de incertidumbre del conjunto de datos S :

$$H(S) = - \sum_{i=1}^n p_i \log_2(p_i) \quad (2)$$

donde:

- p_i = proporción de ejemplos pertenecientes a la clase i .
- n = número total de clases.

2) **Ganancia de información:** mide la reducción de entropía al dividir el conjunto S según un atributo A :

$$GI(S, A) = H(S) - \sum_{v \in \text{Valores}(A)} \frac{|S_v|}{|S|} \cdot H(S_v) \quad (3)$$

donde:

- S_v = subconjunto de datos donde el atributo A toma el valor v .
- $|S|$ = número total de instancias.

3) Criterio de selección del atributo: se selecciona el atributo con mayor ganancia de información:

$$A^* = \arg \max_A GI(S, A) \quad (4)$$

4) Exactitud (Accuracy): mide la proporción de predicciones correctas:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (5)$$

5) Tasa de error (Classification Error): mide la proporción de clasificaciones incorrectas:

$$Error = \frac{FP + FN}{TP + TN + FP + FN} \quad (6)$$

6) Sensibilidad (Recall): mide la capacidad del modelo para identificar correctamente los positivos reales:

$$Recall = \frac{TP}{TP + FN} \quad (7)$$

7) Precisión (Precision): mide la proporción de instancias correctamente clasificadas como positivas:

$$Precision = \frac{TP}{TP + FP} \quad (8)$$

8) Promedio ponderado: RapidMiner calcula el promedio ponderado de las métricas para ambas clases:

$$M_{weighted} = \sum_{i=1}^n w_i \cdot M_i \quad (9)$$

donde:

- w_i = peso asignado a cada clase.
- M_i = valor de la métrica correspondiente.

3. Procedimiento del algoritmo ID3

Para la construcción del árbol de decisión mediante el algoritmo ID3, se siguió el procedimiento descrito a continuación:

1. **Cálculo de la entropía inicial:** se calculó la entropía del conjunto total de entrenamiento, considerando la proporción de ejemplos pertenecientes a cada clase (positive y negative).
2. **Cálculo de la ganancia de información:** para cada atributo se calcularon las entropías de los subconjuntos generados por sus valores posibles, con el fin de obtener la ganancia de información.
3. **Selección del mejor atributo:** se seleccionó como nodo raíz el atributo que presentó la mayor ganancia de información, ya que es el que mayor reducción de incertidumbre proporciona.
4. **Partición del conjunto de datos:** el conjunto original se dividió en subconjuntos según los valores del atributo seleccionado.
5. **Construcción recursiva del árbol:** se repitieron los pasos anteriores de manera recursiva para cada subconjunto, generando los niveles sucesivos del árbol.
6. **Criterio de parada:** el proceso finalizó cuando todos los ejemplos de un nodo pertenecían a la misma clase, cuando no existían más atributos disponibles o cuando el subconjunto era vacío.
7. **Obtención del árbol final:** se obtuvo un árbol de decisión completo, compuesto por nodos internos que representan atributos, ramas que indican valores posibles y hojas que contienen la clasificación final.

4. Metodología

Para el desarrollo de la práctica se siguió una metodología estructurada por etapas, con el fin de garantizar un análisis ordenado y claro del proceso de clasificación mediante árboles de decisión:

1. **Lectura de datos:** se cargó la base de datos **Tic-Tac-Toe Endgame**, la cual ya se encontraba dividida en los conjuntos de entrenamiento (train), prueba (test) y nuevos datos (new data).
2. **Análisis de atributos:** se identificaron los atributos del conjunto de datos, sus posibles valores y la variable de clase, con el objetivo de comprender la estructura de la información.
3. **Cálculos manuales en Excel:** se realizaron los cálculos necesarios en Microsoft Excel para la obtención de las entropías, ganancias de información y la construcción manual del árbol de decisión, con el fin de validar el procedimiento matemático del algoritmo ID3.
4. **Construcción del modelo:** se generó el árbol de decisión aplicando el algoritmo ID3, siguiendo el procedimiento matemático descrito en la sección correspondiente.
5. **Evaluación del modelo:** se aplicó el árbol obtenido sobre el conjunto de prueba, construyendo la matriz de confusión y calculando las métricas de desempeño: exactitud, precisión, sensibilidad y tasa de error.
6. **Rastreo de nuevos datos:** se analizaron los objetos del conjunto **new data**, mostrando la trayectoria seguida dentro del árbol de decisión hasta llegar a la clasificación final.
7. **Comparación con software:** se utilizó la herramienta RapidMiner para generar un árbol de decisión mediante el algoritmo ID3 y comparar los resultados obtenidos con los calculados manualmente en Excel.

5. Pruebas y Resultados Obtenidos en RapidMiner

Para evaluar el desempeño del árbol de decisión generado mediante el algoritmo ID3, se utilizó el conjunto de prueba proporcionado en la base de datos. La evaluación se realizó empleando la herramienta RapidMiner, obteniendo como resultado la matriz de confusión y las métricas estadísticas correspondientes.

5.1. Matriz de Confusión

La matriz de confusión obtenida se muestra en la Tabla 1.

A partir de esta matriz se calcularon las siguientes métricas:

Real / Predicho	Positive	Negative
Positive	32	20
Negative	18	30

Tabla 1: Matriz de confusión del modelo ID3 generada en RapidMiner

- **Exactitud (Accuracy):** 62.00 %
- **Tasa de error:** 38.00 %
- **Sensibilidad (Recall):** 62.00 %
- **Precisión (Precision):** 62.02 %

Los resultados obtenidos indican que el modelo presenta un desempeño moderado, logrando clasificar correctamente aproximadamente dos terceras partes de los casos evaluados.

5.2. Rastreo de trayectorias (New Data)

Para analizar el comportamiento del árbol de decisión, se rastrearon 10 objetos pertenecientes al conjunto **new data**, observando la trayectoria seguida dentro del árbol hasta alcanzar una hoja final o detectar ramas no existentes.

- **Objeto 1:** positive
 Trayectoria: middle-middle-square = x $\rightarrow$ top-left-square = o $\rightarrow$ bottom-right-square = o $\rightarrow$ top-right-square = b
 Hoja final: positive
- **Objeto 2:** No clasificado (rama faltante)
 Trayectoria: middle-middle-square = x $\rightarrow$ top-left-square = o $\rightarrow$ bottom-right-square = b $\rightarrow$ top-middle-square = o
 Detalle: El objeto tiene top-right-square = b; sin embargo, en esta rama el árbol solo contempla valores o y x, por lo que corresponde a una combinación no observada durante el entrenamiento.
- **Objeto 3:** positive
 Trayectoria: middle-middle-square = x $\rightarrow$ top-left-square = o $\rightarrow$ bottom-right-square = x $\rightarrow$ bottom-left-square = o $\rightarrow$ middle-left-square = x $\rightarrow$ middle-right-square = x
 Hoja final: positive
- **Objeto 4:** positive
 Trayectoria: middle-middle-square = x $\rightarrow$ top-left-square = o $\rightarrow$ bottom-right-square = o $\rightarrow$ top-right-square = b

Hoja final: positive

■ **Objeto 5:** No clasificado (rama faltante)

Trayectoria: $\text{middle-middle-square} = x \rightarrow \text{top-left-square} = o \rightarrow \text{bottom-right-square} = x \rightarrow \text{bottom-left-square} = b$

Detalle: El objeto presenta $\text{top-middle-square} = o$; no obstante, en esta rama el árbol solo contempla valores b y x .

■ **Objeto 6:** negative

Trayectoria: $\text{middle-middle-square} = o \rightarrow \text{top-left-square} = x \rightarrow \text{top-middle-square} = b \rightarrow \text{bottom-left-square} = b \rightarrow \text{middle-right-square} = o$

Hoja final: negative

■ **Objeto 7:** negative

Trayectoria: $\text{middle-middle-square} = x \rightarrow \text{top-left-square} = x \rightarrow \text{bottom-right-square} = o \rightarrow \text{top-middle-square} = b \rightarrow \text{bottom-left-square} = o \rightarrow \text{bottom-middle-square} = o$

Hoja final: negative

■ **Objeto 8:** positive

Trayectoria: $\text{middle-middle-square} = x \rightarrow \text{top-left-square} = o \rightarrow \text{bottom-right-square} = o \rightarrow \text{top-right-square} = x \rightarrow \text{bottom-left-square} = o \rightarrow \text{middle-left-square} = x$

Hoja final: positive

■ **Objeto 9:** positive

Trayectoria: $\text{middle-middle-square} = o \rightarrow \text{top-left-square} = o \rightarrow \text{bottom-right-square} = o \rightarrow \text{top-right-square} = x$

Hoja final: positive

■ **Objeto 10:** positive

Trayectoria: $\text{middle-middle-square} = o \rightarrow \text{top-left-square} = o \rightarrow \text{bottom-right-square} = o \rightarrow \text{top-right-square} = x$

Hoja final: positive

Interpretación del rastreo. El rastreo de trayectorias permite comprender cómo el árbol de decisión toma sus decisiones internas, mostrando la secuencia de atributos evaluados desde la raíz hasta una hoja final. Cuando se alcanza una hoja, se obtiene una clasificación (positive o negative). Sin embargo, en algunos casos el objeto puede llegar a una combinación de valores para la cual no existe una rama en el árbol, lo que indica que dicha configuración no apareció en los datos de entrenamiento. Estos casos se reportan como *No clasificado (rama faltante)* y evidencian una limitación del modelo frente a datos no observados previamente.

5.3. Árbol de decisión obtenido

El árbol de decisión generado mediante el algoritmo ID3 presenta la estructura jerárquica que permite clasificar los estados del juego del gato. Debido a su tamaño y nivel de detalle, el árbol completo se presenta en la sección de apéndices para facilitar su correcta visualización e interpretación.

El árbol completo puede consultarse en los Apéndices, anexo :Tree RapidMiner.txt

6. Pruebas y Resultados Obtenidos Manualmente

Para evaluar el desempeño del árbol de decisión construido de forma manual mediante el algoritmo ID3, se utilizó el conjunto de prueba proporcionado en la base de datos. Los cálculos fueron realizados en Microsoft Excel, obteniendo como resultado la matriz de confusión y las métricas estadísticas correspondientes.

6.1. Matriz de Confusión

La matriz de confusión obtenida a partir de los cálculos manuales se muestra en la Tabla 2.

Real / Predicho	Positive	Negative
Positive	38	12
Negative	27	23

Tabla 2: Matriz de confusión del modelo ID3 calculada manualmente

A partir de esta matriz se calcularon las siguientes métricas:

- **Exactitud (Accuracy):** 61.00 %
- **Tasa de error:** 39.00 %
- **Sensibilidad (Recall):** 76.00 %
- **Precisión (Precision):** 58.46 %

6.2. Árbol de decisión obtenido manualmente

El árbol de decisión fue construido de forma manual aplicando el algoritmo ID3, utilizando los cálculos realizados en Excel para la obtención de entropías y ganancias de información. La estructura jerárquica del árbol permite clasificar los estados del juego del gato a partir de los atributos más relevantes.




Figura 1: Árbol de decisión generado manualmente mediante el algoritmo ID3

El procedimiento puede consultarse en los Apéndices, anexo :Algoritmo ID Manual .xlsx

7. Comparación de Resultados Obtenidos

7.1. Comparación de matrices de confusión

En la Figura 5 se muestran, de forma paralela, las matrices de confusión correspondientes al modelo manual y al modelo generado en RapidMiner, con el objetivo de facilitar su análisis visual y comparativo.

Real / Predicho	Pos.	Neg.
Positive	38	12
Negative	27	23

Tabla 3: Matriz manual

Real / Predicho	Pos.	Neg.
Positive	32	20
Negative	18	30

Tabla 4: Matriz RapidMiner

Tabla 5: Comparación de matrices de confusión

El modelo manual presenta una mayor cantidad de verdaderos positivos, lo que se traduce en una mayor sensibilidad. No obstante, el modelo generado en RapidMiner logra una mejor distribución entre verdaderos positivos y verdaderos negativos, reduciendo los falsos positivos y mejorando el equilibrio general de la clasificación. Esto permite concluir que ambos modelos presentan com-

portamientos similares, aunque con fortalezas distintas dependiendo del tipo de error que se desee minimizar.

7.2. Comparación de métricas de desempeño

En la Tabla 6 se presenta la comparación directa de las principales métricas de desempeño obtenidas en ambos modelos.

Métrica	Manual (Excel)	RapidMiner
Exactitud (Accuracy)	61.00 %	62.00 %
Sensibilidad (Recall)	76.00 %	62.00 %
Precisión (Precision)	58.46 %	62.02 %
Tasa de error	39.00 %	38.00 %

Tabla 6: Comparación de métricas de desempeño

Los resultados muestran que el modelo manual obtiene una mayor sensibilidad, lo que indica una mejor capacidad para detectar correctamente los casos positivos. Por otro lado, el modelo generado con RapidMiner presenta una ligera mejora en la exactitud y en la precisión, reflejando un desempeño general más equilibrado. En conjunto, ambos enfoques presentan resultados similares, validando la correcta implementación del algoritmo ID3 tanto de forma manual como mediante software especializado.

8. Aplicación del Software Seleccionado

Para la validación de los resultados obtenidos manualmente, se utilizó el software *RapidMiner*, el cual permite aplicar algoritmos de minería de datos de manera gráfica y eficiente.

El procedimiento seguido fue el siguiente:

1. Se cargó la base de datos **Tic-Tac-Toe Endgame** en la plataforma RapidMiner.
2. Se realizó la separación de los datos en conjuntos de entrenamiento, prueba y nuevos datos, de acuerdo con la estructura proporcionada.
3. Se seleccionó el operador *Decision Tree* utilizando el criterio de división basado en entropía, correspondiente al algoritmo ID3.
4. Se configuraron los parámetros del modelo y se ejecutó el proceso para generar el árbol de decisión.

5. Se evaluó el desempeño del modelo mediante el operador *Performance*, obteniendo la matriz de confusión y las métricas de evaluación.
6. Finalmente, se realizó la clasificación de los objetos del conjunto **new data** para analizar la trayectoria seguida dentro del árbol y validar los resultados obtenidos.

El uso de RapidMiner permitió verificar la correcta aplicación del algoritmo ID3 y contrastar los resultados manuales con los obtenidos mediante software especializado.

9. Conclusiones

En esta práctica se implementó el algoritmo ID3 para la construcción de un árbol de decisión utilizando la base de datos *Tic-Tac-Toe Endgame*. A partir del conjunto de entrenamiento se generó un modelo de clasificación basado en entropía y ganancia de información, lo que permitió comprender el proceso de toma de decisiones y la selección de los atributos más relevantes.

La evaluación del modelo realizada con RapidMiner arrojó una exactitud del 62.00 %, una precisión del 62.02 % y una sensibilidad del 62.00 %, lo que indica un desempeño aceptable del clasificador. Estos resultados muestran que el modelo logra identificar correctamente una parte importante de los estados del juego, aunque aún presenta limitaciones al enfrentarse a configuraciones más complejas del tablero.

El análisis de la matriz de confusión permitió observar la presencia de falsos positivos y falsos negativos, lo cual evidencia que existe cierto solapamiento entre las clases. Esto dificulta la clasificación perfecta de los datos y sugiere que el árbol de decisión, aunque funcional, no es suficiente para modelar todas las combinaciones posibles del juego con total precisión.

La implementación manual del algoritmo en Excel permitió reforzar la comprensión del procedimiento matemático involucrado en la construcción del árbol. Al comparar estos resultados con los obtenidos en RapidMiner, se observó un comportamiento similar, lo que valida la correcta aplicación del algoritmo y confirma la utilidad del software como herramienta de apoyo.

El rastreo de los nuevos datos facilitó la interpretación del funcionamiento interno del árbol, permitiendo seguir paso a paso el proceso de clasificación. Esto resalta una de las principales ventajas de los árboles de decisión: su facilidad de interpretación y comprensión.

Finalmente, los resultados obtenidos sugieren que fue posible analizar y clasificar los datos mediante ambos métodos; sin embargo, al haberse obtenido valores de precisión relativamente bajos, el modelo no puede considerarse completamente confiable para realizar predicciones en todos los casos.

10. Apéndices

- A) Marco teórico (conceptos y fórmulas).
- B) Manual de usuario.
- C) Manual técnico.
- D) Anexos:
 - Árbol de decisión generado en RapidMiner.
 - Archivo de cálculos manuales en Excel.

Referencias

- [1] Instituto Tecnológico de Nuevo Laredo (2023). Algoritmo ID3 — Apuntes de Inteligencia Artificial. Recuperado de: <https://nlaredo.tecnm.mx/takeyas/Apuntes/Inteligencia%20Artificial/Apuntes/IA/ID3.pdf>. Fecha de consulta: 16/02/2026.
- [2] RapidMiner (2024). RapidMiner Documentation. Recuperado de: <https://docs.rapidminer.com/9.8/hub/web-apps/index.html>. Fecha de consulta: 16/02/2026.
- [3] scikit-learn (2024). Decision Trees — scikit-learn documentation. Recuperado de: <https://scikit-learn.org/stable/modules/tree.html>. Fecha de consulta: 16/02/2026.